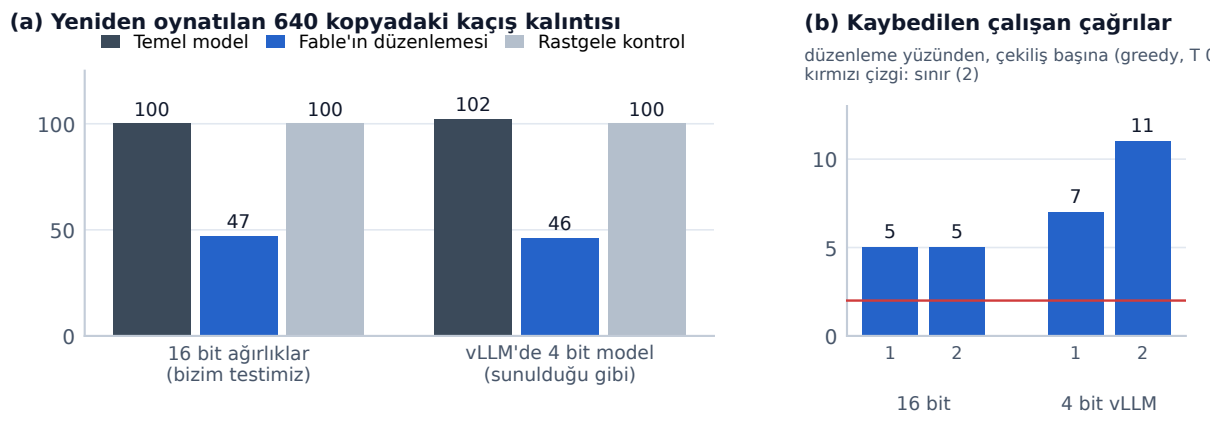
(a) Yeniden oynatılan 640 kopyadaki kaçış kalıntısı
Temel model
Fable'ın düzenlemesi
Rastgele kontrol
100
50
0
100
47
100
102
46
100
16 bit ağırlıklar
(bizim testimiz)
vLLM'de 4 bit model
(sunulduğu gibi)
(b) Kaybedilen çalışan çağrılar
düzenleme yüzünden, çekiliş başına (greedy, T
kırmızı çizgi: sınır (2)
10
5
0
5
5
7
11
1
2
1
2
16 bit
4 bit vLLM