(a)

1 Editör
Opus 5.5, Fable 5.1 ya da GPT-6 Astra, kum havuzunda tek başına

- ✓ her ağırlığı okuyabilir
- ✓ 25 ileri geçiş isteği (Astra 10), 4 eğitim deposundaki çağrılarda
- ✓ kapalı biçimli fit (en küçük kareler)
- ✗ gradyan, geri yayılım ya da optimizer
- ✗ test depoları

2 Tek düzenleme
W + B·A: seçilen ağırlık matrislerine küçük bir değişiklik (LoRA biçimi), testten önce dondurulduk

3 Önceden planlı test
kayıtlı 320 düzenleme çağrısı; hiçbir editörün görmediği 69 depodaki 101 görevden, her biri iki kez

Karşılaştırılan: temel model, düzenleme ve aynı boyutta 2 rastgele kontrol

4 Karar
Geçmek için ikisi de:

- görev başına daha az kaçış kalıntısı
- üç yan etki korumasının üçü

(b)

Kayıtlı ajan çalışması (sabit tutulur)

Görev: issue metni ve talimatlar

read_file → dosya içeriği, kaçışlı

... önceki adımlar ...

`edit_file(path, old_text= ? , new_text)`

Yalnızca eski metni yeniden üret

- temel model
- düzenleme
- rastgele kontrol

aynı istem, token token

Harness'ın kendi eşleyicisiyle puanla

Eski metin kabul edildi mi, yoksa bulunamadı mı?

Eski metinde kaçış kalıntısı var mı?

Sunulan modelle kontrol, görülmemiş depolardaki çağrılarda:
yeniden oynatma 103 başarısızlığın 95'ini ve 213 başarının 213'ünü yeniden üretti.